

CAI / NFP107

Conception et administration de bases de données

Introduction aux SGBD

Sommaire

Les Données

Les Fichiers

Les Bases de données

Les SGBD

Architectures des applications utilisatrices des BDD

Les Données: définition

Informatique : traitement automatique de l'information

L'information est représentée par des données:

nom, age, distance, adresse, prix, date de naissance etc.

Les Données:

Toute donnée a un **type** (elle est typée)

exemple: Entier, Texte, Date etc.

Son type définit la **nature de son codage** et les **opérations autorisées**

Données élémentaires : non décomposables

exemple: Age

Données composée : constituée de données élémentaires ou composées

exemple: Adresse postale

Les Données: leur stockage

Stockées en mémoire:

Ecriture, Lecture, Traitement, Ecriture (cycle)

En mémoire centrale: RAM (perdues à l'arrêt du système)

En mémoire secondaire: disques (stockage permanent)

En mémoire tertiaire: bandes, DVD, cloud, etc. (archivage)

Les Données: leur exploitation

Application : Un ensemble de programmes informatiques qui consomment, traitent et produisent des données pour réaliser des fonctionnalités.

Exemple: Calcul de la paye, Comptabilité, Facturation

A l'origine : les données sont stockées dans des « **Fichiers** »

Les applications manipulent des fichiers (lecture/écriture)

Les Fichiers pour le stockage des données

Fichier

Un Fichier est un ensemble de données semblables physiquement regroupées sur un support.

Exemple: Fichier des clients, Fichier des comptes, Fichier des salariés

Un Fichier comporte des « Articles » ou « Enregistrements »


Exemple: Les données d'un Client

Un « Article » est composé de « Rubriques » (données élémentaires)

Dupont	Pierre	05/02/1962	2 Place de la Paix
--------	--------	------------	--------------------

Exemple: Nom, Prénom, date de naissance et Adresse d'un Client

Utilisation des Fichiers par les applications



Les applications « Facturation » et « Paye » utilisent des données stockées dans des fichiers

Utilisation des Fichiers par les applications

Redondance des données :

- Multiplication des tâches de saisies, mise à jour
- Consommation de volumes de stockages
- Incohérences

Pas de partage des données : accès simultanés impossibles

Difficulté de localisation : où trouver les fichiers

Difficulté d'exploitation : Mode d'accès aux enregistrements.

Comment sont organisées les données (structure) ?

Opération sur les Fichiers

Créer / Détruire un fichier

Ouvrir / Fermer un fichier

Ajouter / Modifier / Supprimer un « Enregistrement »

Rechercher et lire un « Enregistrement » particulier en fonction de la **valeur** de certaines de ses **rubriques**.

Lire un après l'autre tous les « Enregistrements » du fichier.

Opération sur les Fichiers

Clé : Rubrique dont la valeur **permet d'identifier un « Article » particulier d'un fichier.**

Chemin d'accès : structure de données permettant d'accéder efficacement aux « Articles » d'un fichier en utilisant une **clé d'accès.**

Page mémoire : Unité de lecture et d'écriture sur le support mémoire

Organisation d'un fichier : stratégies de stockage des « Articles » dans les pages mémoire.

Séquentielle, Relative, Aléatoire, Séquentielle indexées

Organisation Séquentielle

Stockage des « Enregistrements » **les uns à la suite des autres**

Les « Enregistrements » peuvent être ordonnés selon la valeur d'une rubrique.

- Gestion Simple
- Mode d'accès peu performant
- Accès en séquentiel uniquement

Organisation Relative

Stockage des « Enregistrements » **de longueur fixe les uns à la suite des autres**

Les « Enregistrements » sont accédés avec leur **rang en tant que clé d'accès.**

Accès à la page contenant

l'enregistrement de rang $I \rightarrow I / (\text{Taille de page mémoire} / \text{Taille article}) + 1$

La clé d'accès discriminante doit être numérique et continue

Organisation Aléatoire (Random Access) ⁽¹⁾


Répartition des enregistrements dans des paquets en fonction de la valeur de leur « Rubrique » clé.

Une fonction de « Hachage » permet de déterminer le paquet cible à partir de la valeur « Rubrique » clé.

$F(\text{valeur de la rubrique Clé}) \rightarrow \text{n}^\circ \text{ Paquet cible}$

Si la fonction de Hachage n'est pas injective il y a des risques de « Collisions » : « Même résultat pour une clé différente »

Organisation Aléatoire (Random Access) (2)



Limitations de l'organisation aléatoire : Recherche que sur égalité de valeur de la clé.

Organisation Séquentielle indexée

Fichier trié selon une clé d'accès

Fichier complémentaire pour associer valeur de clé à une page mémoire.

Possibilité d'utiliser des Structures de données arborescentes.

Index primaire, index secondaire, ...

Les Fichiers : Conclusion

Permet de stocker des données

Différentes organisations et leurs modes d'accès (+ ou moins efficaces)

Utilisés pour mettre à disposition des **données aux applications**
(méthode qui a fait ses preuves)

Pas idéal: redondance, accès simultanés impossibles, rubriques non structurées

Les Bases De Données (BDD) et les Systèmes de Gestion de BDD (SGBD)

Base de données

Ensemble de données Persistantes, Fortement structurées (Structure définie dans un schéma par opposition aux programmes utilisateurs de fichiers)

Autre définition: « Ensemble de données structurées enregistrées qui sont accessibles de façon sélective par plusieurs utilisateurs. »

Une BDD est gérée par un **Système de Gestion de Bases de Données (SGBD)**

Base de données : Objectifs

Proscrire la redondance des données
(cohérence des données)

Partage des données entre tous les utilisateurs

Contrôle d'accès : gestion et contrôle des accès simultanés, contrôle des droits d'accès

Facilité d'accès aux données et amélioration des performances

SGBD : fonctions attendues ⁽¹⁾

Description des données qui seront stockées

(Schéma = structure, type, règles etc.)

Manipulation des données : Ajout, Modification, Suppression des données

Extraction et traitements des données : filtrage, tri, projection, agrégation. *(langage dédié, langage naturel)*

Protéger les Bdd des accès interdits ou mal intentionnés

(Utilisateurs, Mots de passe, Rôles, privilèges)

SGBD : fonctions attendues ⁽²⁾


Résoudre les problèmes d'accès simultanés :
(verrou, stratégie pour éviter les interblocages)

Vérifier l'application des règles définies lors de la description des données

Garantir la consistance des données
(Mode Transactionnel)

Mettre à disposition un mécanisme de reprise en cas de panne
(Sauvegarde/Restauration, Journaux)

Utilisation d'un SGBD par les applications



Les applications « Facturation » et « Paye » accèdent aux données en utilisant le SGBD. (Pas de redondance des données de « Ventes »)

Base de données : en résumé

Collection de données reliées

Ventes, Salaire → le vendeur est un salarié

Données Stockées sans redondances inutiles

- *Salaire comporte les rubriques signalétiques du salarié: matricule, nom, prénom etc.*
- *Dans Ventes, il n'y a pas la rubrique nom du vendeur mais son matricule*

Données mises à disposition de multiples applications

Vente est utilisé aussi bien par l'application Facturation que Paye

Structures et formats de stockage indépendant des applications utilisatrices

Les applications obtiennent les informations, peu importe leur origine (Boulot du SGBD)


Manipulation des données par l'application à travers les primitives mise à dispo par le SGBD

Seul le SGBD est habilité à Créer, Modifier ou supprimer des données

Schéma cohérent, prévu pour évoluer en fonction des nouveaux besoins

Choix des rubriques et de leur répartition « en toute intelligence » (Conception de BDD)

Architecture d'un SGBD



SGBD : Avantages

Centralisation des données

sauvegarde facilitée, intégrité des données

Contrôle centralisé de l'accès aux données

Référentiel des utilisateurs et de leurs privilèges

Traitement performant et optimisé

Index, statistique, cache

Accès aux données Indépendamment de la structure logique ou physique des données

Boîte noire, évolution facilitée (Indépendance Physique et logique)

Principe d'indépendance physique

Manipulation des données sans aucune connaissance des structures de stockage

- Les utilisateurs manipulent des représentations abstraites des données
- Structure logique ou conceptuelle != Structure physique
- Possibilité d'optimiser le stockage sans impacter les utilisateurs

Structure logique

Employé : **Nom**
 Adresse
 Fonction
 Enfants **Prénom**
 Age



Structure physique

- 1 seul fichier
ou bien
- 1 fichier **Employé** et 1 fichier **Enfants** et des pointeurs entre les deux

Principe d'indépendance logique

Les utilisateurs travaillent sur une représentation logique limitée aux données qui leurs sont nécessaires

- Le SGBD assemble et fournit cette « vue » logique des données
- Les utilisateurs ne sont pas impactés lorsque des données qu'il n'utilisent pas sont modifiées.

- Exemple : Les données d'un hôpital : médecins, malades, chambres, ...
 - Application n° 1 : Suivi des malades (Nom, N° SS, N° Chambre, Médecin)
 - Application n° 2 : Données d'un médecin (Nom, N° SS, N° Chambre, Thérapie)
 - Application n° 3 : Gestion du personnel : les médecins (Nom, Grade, Spécialité, Salaire)

Architecture ANSI/SPARC

Niveau externe:

Vue partielle des données, sous-ensemble du niveau conceptuel destinée à des utilisateurs particuliers.


Niveau conceptuel (indépendant du SGBD):

Vue abstraite des données dépendant du type de SGBD (hiérarchique, réseau, relationnel, objet)
Sans se soucier des contraintes (performance, espace ...) liées à l'implantation physique.

Niveau interne (totalement dépendant du SGBD):

Organisation physique des données pour implanter la BDD.

(Proposée en 1975 par Charles Bachman qui reçut le prix Turing)



Architecture ANSI/SPARC : Les 3 niveaux

Niveau externe:


2 vues pour 2 utilisations différentes

Niveau conceptuel :

Le schéma comportant toutes les données

Niveau interne :

Les données stockées sous forme d'une structure C. Enregistrement dans des fichiers



Architecture ANSI/SPARC :

Avantages/Limitations

Avantages :

Limitation des impacts liés au changement de matériel, de système d'exploitation, de logiciel client.

La **vue externe** de chaque utilisateur peut être **modifiée sans impacter celle des autres**

Limitations :

Concept d'une BDD globale à toutes les applications: mise en place difficile en pratique (pb techniques et organisationnels)

Schéma ou vue externe : facile de mettre à disposition des données pour lecture. Mais pour les mises à jour ?

Types d'utilisateurs des SGBD ⁽¹⁾

L'administrateur de la base (DBA):

Affectation des droits sur la base de données aux applications et individus qui y sont autorisés.

(différents droits: lecture, écriture, suppression des données, création des vues)

Optimisations des performances d'accès aux données (supervision)

(index, relocalisation fichier, cluster, traitements de maintenance, dénormalisation)

Sauvegardes et procédures de reprise après les pannes

(cycles de sauvegarde, différentielle/complète, sauvegarde à chaud, restauration)

Types d'utilisateurs des SGBD ⁽²⁾

Le Programmeur :

Ecrit des applications utilisatrices de la base de données.

(programmes de maintenance, « requêtes », accès à la BDD à travers des pilotes)

Crée les tables et éléments associés (index et vues) utilisées par ses applications

(script de création de la Bdd et des index et vues)

Ecrit les scripts d'import/export pour reprise ou changement de BDD

(BDD $\leftrightarrow$ format pivot $\leftrightarrow$ BDD)

Types d'utilisateurs des SGBD ⁽³⁾

L'Utilisateur final :

Accède uniquement aux données qui lui sont utiles.
(vues mise à disposition au niveau externe)

Exploitation de ces données :

- A travers d'applications métiers
- En utilisant des outils (*requêteur graphique*)
- Rapport et tableau de bord (*BI, OLAP*)

Les langages pour exploiter les SGBD

LDD : Langage de Définition des Données

Permet de créer les schémas, les vues, les index, les droits, les règles etc.

LMD : Langage de Manipulation des Données

Permet de créer, lire et supprimer les données en respectant les schémas et leurs règles.

Langage Hôte : Langage de programmation enrichi d'instructions de manipulation de données

Instruction de LMD embarquées dans un langage procédural

L4G : Langage de 4^{ème} génération :

Outil intégrant un langage procédural avec des Instructions de LMD, des composants graphiques pour la présentation des données et des générateurs de rapports.

Interface BDD / Programme

Utilisation d'un protocole dédié: Programme $\leftrightarrow$ SGBD

Permet aux programmes d'obtenir des services du SGBD.

Mode compilé : instruction incluses à la compilation du code

*Les instructions pour l'exploitation de la Bdd sont ajoutés au code compilé
(Pro*C pour Oracle)*

Utilisation Bibliothèque ou Pilote propriétaire

Utilisation Bibliothèque ou Pilote « Pivot »:

Utilisation d'une Bib en dynamique (ADO, JDBC, ODBC)

Les différents types de SGBD: Hiérarchique

SGBD hiérarchique :


- Données représentées sous la forme d'un arbre
- Les liens sont exclusivement de type 1 : N
- La structure d'arbre utilise des pointeurs pour décrire le chemin d'accès aux données.

Avantages:

- Adéquation du modèle avec les domaines à structure arborescente
- Simplicité du modèle et implémentation facile

Inconvénients :

- Impossibilité de représenter directement les liens N : M qui entraînent des redondances.
- Indépendance logique très réduite.



Les différents types de SGBD: Réseau

SGBD réseau :


- Données représentées sous la forme d'un graphe
- La structure de graphe utilise des pointeurs pour décrire le chemin d'accès aux données.

Avantages:

- Représentation naturelle des liens
- Pas de redondances

Inconvénients :

- Pas d'indépendance vis à vis des stratégies d'accès



Les différents types de SGBD: Objet

SGBD objet (SGBDOO):


- Données représentées sous la forme d'un graphe d'objets
- Pointeur entre instance d'objets.

Avantages:

- Introduction de la notion d'héritage
- Navigation facile
- Persistance facile

Inconvénients :

- Pas de normalisation
- Ne se sont toujours pas imposés depuis les années 90 (approche hybride plus répandue: ORM)
- Gestion de l'espace dédié à la persistance (pb ZOPE)



Les différents types de SGBD: Relationnel

SGBD relationnel :

- Basé sur la théorie mathématique des relations (ensembles et leur relation)
- Navigation entre les différents « Fichiers » ou « Relation » ou « Tables » en utilisant des rubriques particulières: les « Clés étrangères »

Avantages:

- Langage de requête non procédural puissant, simple (algèbre Relationnelle, QBE)
- Types de SGBD les plus répandus, Langage SQL normalisé

Inconvénients :

- « Reconstitution de l'information » peut être complexe
- Performance pas toujours au rendez-vous

Les différents types de SGBD: Relationnel

Département

code dépt	nom dépt
MMath	
I	Informatique

Cours

code cours	intitulé	nb d'heures	code dépt
A12	algèbre	100	M
G11	géométrie	50	M
A15	analyse	120	M
I50	programmation	100	I

Etudiant

numéro	nom
14	Jean
18	Jacques
25	Pierre
27	Paul

Inscription

code cours	numéro	date inscription	note
A12	14	12/12/2002	12
A12	18	10/10/2002	10
G11	27	10/10/2002	18
G11	25	10/11/2002	9
G11	14	08/09/2002	18

Les différents types de SGBD: les NoSQL

NoSQL pour Not Only SQL né pour résoudre de nouvelles problématiques :

- Très Gros volume de données → besoin de répartir sur plusieurs serveurs
- Objets complexes et hétérogènes → limite des SGBD relationnels et Transactionnels

Avantages:

- Distribution des données sur plusieurs datacenter
- Paralléliser les traitements

Inconvénients :

- Très récents, peu de support
- Pas de standard par opposition à SQL

Les différents types de SGBD: différents types NoSQL

	Key/Value Store	Column Store	Document Store	Graph Store
Design	Key/Value pairs; indexed by Key	Columns and Column Families. Directly accesses the column values	Multiple Key/Value pairs form a document. Values may be nested documents or lists as well as scalar values	Focus on the <u>connections</u> between data and fast navigation through these connections
Scalability / Performance	+++	+++	++	++
Aggregate-Oriented	Yes	Yes	Yes	No
Complexity	+	++	++	+++
Inspiration / Relation	Berkley DB, Memcached, Distributed Hashmaps	SAP Sybase IQ, Google BigTable	Lotus Notes	Graph Theory
NOSQL Products	Voldemort Redis Riak	HBase Cassandra Hypertable	MongoDB CouchDB Couchbase	Neo4j OrientDB DEX InfiniteGraph [Triple and Quad Stores]

Les différents types de SGBD : Les produits du marché

Modèles	Produits	Normes	Apparition
Hiérarchique	IMS/DL1		Années 1960
	System 2000		
Réseau	IDMS	CODASYL ANSI/SPARC	Années 1970
	IDS		
	Socrate		
	Total		
	MDBS		
Relationnel	Oracle	SQL	Années 1980
	DB2		
	Ingres		
	Informix		
	Sybase		
	SQL Server		
	mySQL		
Objet	Versant	ODMG	Années 1990 35
	GemStone		
	ObjectStore		


Autres SGBD Relationnels :

My SQL	Open Source	- UNIX / WINDOWS
PostGreSQL	Open Source	- UNIX / WINDOWS

Les Bases De Données (BDD) dans les architectures d'applications


BDD Centralisée

Données, SGBD et traitements sur même ordinateur (Mainframe)



Architecture Client/Serveur

Données et SGBD sur un serveur, les traitements sur les postes clients utilisent le SGBD du serveur.




BDD Distribuées / Réparties

Différents cas :

L'application utilise plusieurs BDD mais une seule à la fois

L'application utilise plusieurs BDD (SGBD) en même temps
(Parallélisation des traitements par l'application)

L'application utilise une seule BDD à travers un seul SGBD,
la BDD a été partitionnée au niveau physique
(Parallélisation des accès aux données par le SGBD)



Les Entrepôts de données (Data Warehouse)

BDD pour applications de supervision, décisionnelles ou BI.

- Analyses de données

- Tableaux de bord et rapports

OLTP (On Line Transactional Processing):

- Mêmes BDD que celle utilisée par les applications

- Données produites par les applications

- But: suivre et piloter l'activité en temps réel

OLAP (On Line Analytical Processing) Cube (Mondrian)

- Données « non vivantes » alimentées par traitements en différées

- Données agrégées

- But: prévoir l'avenir, prendre des décisions, analyser le passé

Entrepôt de données: OLTP vs OLAP

	OLTP System Online Transaction Processing (Operational System)	OLAP System Online Analytical Processing (Data Warehouse)
Source of data	Operational data; OLTPs are the original source of the data.	Consolidation data; OLAP data comes from the various OLTP Databases
Purpose of data	To control and run fundamental business tasks	To help with planning, problem solving, and decision support
What the data	Reveals a snapshot of ongoing business processes	Multi-dimensional views of various kinds of business activities
Inserts and Updates	Short and fast inserts and updates initiated by end users	Periodic long-running batch jobs refresh the data

Queries	Relatively standardized and simple queries Returning relatively few records	Often complex queries involving aggregations
Processing Speed	Typically very fast	Depends on the amount of data involved; batch data refreshes and complex queries may take many hours; query speed can be improved by creating indexes
Space Requirements	Can be relatively small if historical data is archived	Larger due to the existence of aggregation structures and history data; requires more indexes than OLTP
Database Design	Highly normalized with many tables	Typically de-normalized with fewer tables; use of star and/or snowflake schemas
Backup and Recovery	Backup religiously; operational data is critical to run the business, data loss is likely to entail significant monetary loss and legal liability	Instead of regular backups, some environments may consider simply reloading the OLTP data as a recovery method

Conclusion

Les BDD ont pris le relais des fichiers pour résoudre les problèmes :

- de redondances de données
- De contrôle d'accès et de haute disponibilité
- de garanti de l'intégrité
- d'exposition et de partage de la structure.

SGBD et le modèle ANSI/SPARC permettent **l'indépendance Logique et physique**.

Les BDD relationnelles sont les plus couramment utilisées

Un nouveau courant « NO SQL » : *effet de mode ou le futur des BDD ?*